



## § 7.2 估计量的优良性准则

对于总体的一个参数,可用各种不同的方法去估计它,因此一个参数的估计量不唯一.

如, 当  $X \sim U(0, \theta)$ ,  $\theta$  的矩法估计量为  $2\bar{X}$ , 而极大似然估计量为  $\max_{1 \leq i \leq n} \{X_i\}$ .

在众多的估计量中, 选哪一个更好? 选取的标准是什么?

三个常用的准则:





## 第七章 参数估计 — 估计量的优良性准则

### 估计量的优良性准则(三个常用)

#### 1. 无偏性(样本容量 $n$ 固定)

定义：设  $\hat{\theta}(X_1, X_2, \dots, X_n)$  是未知参数  $\theta$  的估计量，

若  $E(\hat{\theta}) = \theta$ ，则称  $\hat{\theta}$  为  $\theta$  的无偏估计。 等价：  $E(\hat{\theta} - \theta) = 0$

#### 2. 有效性：设 $\hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2(X_1, X_2, \dots, X_n)$

是未知参数  $\theta$  的两个无偏估计量，如果  $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$

则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效 (样本容量 $n$ 固定)

#### 3. 相合性：设 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 $\theta$ 的估计量，

若对任意的  $\varepsilon > 0$ ，有  $\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1$  即  $\hat{\theta} \xrightarrow{P} \theta$

则称  $\hat{\theta}$  为  $\theta$  的相合估计或一致估计。

2页 教师(样本容量 $n$ 充分大,无无偏性的要求)





## 1. 无偏性的意义

$$E(\hat{\theta} - \theta) = 0 \quad \text{或} \quad E(\hat{\theta}) = \theta (\text{参数})$$

误差

随机误差：操作上和其他随机性原因，  
可消除(求平均)；  
系统误差：本身结构上问题  
(不能通过多次平均消除)。

一个估计量如果不是无偏的，就称为有偏估计，称  $E(\hat{\theta} - \theta)$  为估计量  $\hat{\theta}$  的偏差，在科学技术中也称之为  $\hat{\theta}$  的系统误差。

**无偏性的实际意义：**没有系统误差，消除随机误差。





$S^2$  是总体方差  $\sigma^2$  的无偏估计量(重要的结论)

例1: 设总体的方差  $D(X)=\sigma^2>0$ , 则样本方差  $S^2$  是  $\sigma^2$  的无偏估计.

$$\begin{aligned}\text{证明: } (n-1)S^2 &= \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + n\bar{X}^2 \\ &= \sum_{i=1}^n X_i^2 - n\bar{X}^2\end{aligned}$$





**$S^2$  是总体方差  $\sigma^2$  的无偏估计量(重要的结论)**

$$(n-1)S^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

$$(n-1)E(S^2) = \sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2)$$

样本独立同分布性质

$$= nE(X^2) - nE(\bar{X}^2)$$

$$= n\{D(X) + E(X)^2\} - n\{D(\bar{X}) + E(\bar{X})^2\}$$

$$= n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right)$$

$$= (n-1)\sigma^2$$

$$\therefore E(S^2) = \sigma^2$$



**重要结论1:**  $S^2$  是总体方差  $\sigma^2$  的无偏估计

**注:**  $M_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n-1}{n} S^2$  不是  $\sigma^2$  的无偏估计

**重要结论2:** 总体均值  $\mu$  已知时,  $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$  是总体方差  $\sigma^2$  的无偏估计

$$\begin{aligned} E\left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2\right] & \stackrel{\text{样本独立同分布的性质}}{=} \frac{1}{n} \sum_{i=1}^n E[(X_i - E(X_i))^2] \\ &= \frac{1}{n} \sum_{i=1}^n D(X_i) = \frac{1}{n} \times n \times \sigma^2 = \sigma^2 \end{aligned}$$

**思考:** 下列估计量是否总体均值  $E(X)$  的无偏估计量? 哪个更好?

1.  $\bar{X}$    2.  $X_1$    3.  $\frac{X_1 + X_2}{2}$    4.  $0.1X_1 + 0.2X_2 + 0.7X_3$

**注:** 一个未知参数可以有不同且很多的无偏估计量.



无偏估计性及意义

$$E(\hat{\theta}) = \theta \text{ 或 } E(\hat{\theta} - \theta) = 0$$

优点：没有系统误差，相当于从平均意义上使随机误差  
刚好正、负抵消。

缺陷：但并不保证随机误差很小。

若随机误差很大，无偏估计给出的估计值并不  
令人放心的。

例：原料对产品质量偏差无法抵消。

一个优良的估计量，其方差应该较小，以控制  
随机误差。





## 2. 有效性

定义： 设  $\hat{\theta}_1(X_1, X_2, \dots, X_n)$  和  $\hat{\theta}_2(X_1, X_2, \dots, X_n)$  是未知参数  $\theta$  的两个无偏估计量,

若对  $\theta$  的所有可能取值都有  $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$

则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效

设  $\hat{\theta}_0$  是  $\theta$  的无偏估计, 如果对  $\theta$  的任何一个无偏估计量  $\hat{\theta}$  都有  $D(\hat{\theta}_0) \leq D(\hat{\theta})$

则称  $\hat{\theta}_0$  为  $\theta$  的最小方差无偏估计量。

证明无偏性并判断哪个有效例2和例3







## 第七章 参数估计——估计量的优良性准则

例2: 设  $X_1, X_2, \dots, X_n$  为总体  $X$  的一个样本, 证明:

$$\hat{\mu} = \sum_{i=1}^n c_i X_i, c_i \geq 0, \sum_{i=1}^n c_i = 1 \text{ 是总体均值无偏估计量,}$$

其中  $\bar{X}$  是其中最有效估计量.

$$\text{证: } E(\hat{\mu}) = E\left(\sum_{i=1}^n c_i X_i\right) = E(X) \sum_{i=1}^n c_i = E(X)$$

$$D(\hat{\mu}) = D\left(\sum_{i=1}^n c_i X_i\right) = \sigma^2 \sum_{i=1}^n c_i^2 \leq \sigma^2$$

$$\text{函数 } f(c_1, c_2, \dots, c_n) = \sum_{i=1}^n c_i^2 \quad \text{条件极小值}$$

利用拉格朗日乘数法求条件极值, 令

$$L(c_1, c_2, \dots, c_n; \lambda) = \sum_{i=1}^n c_i^2 + \lambda(1 - \sum_{i=1}^n c_i)$$





## 第七章 参数估计——估计量的优良性准则

**例2** 证明:  $\hat{\mu} = \sum_{i=1}^n c_i X_i, c_i \geq 0, \sum_{i=1}^n c_i = 1$  是总体均值无偏估计量,  
其中  $\bar{X}$  是其中最有效估计量.

$$L(c_1, c_2, \dots, c_n; \lambda) = \sum_{i=1}^n c_i^2 + \lambda(1 - \sum_{i=1}^n c_i)$$

$$\begin{cases} \frac{\partial L}{\partial c_i} = 2c_i - \lambda = 0; & (i = 1, 2, \dots, n) \\ \sum_{i=1}^n c_i = 1. \end{cases}$$

解得:  $\lambda = \frac{2}{n} \quad c_i = \frac{1}{n}, \quad i = 1, 2, \dots, n$

即函数  $f(c_1, c_2, \dots, c_n) = \sum_{i=1}^n c_i^2$

的最小值点是  $(\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n})$





# 证明无偏性并判断哪个更有效

优良性准则

例3: 设总体 $X \sim U(0, \theta)$ ,  $\theta > 0$  未知,  $(X_1, X_2, X_3)$ 是取自 $X$ 的一个样本:

- 1) 试证  $\hat{\theta}_1 = \frac{4}{3} \max_{1 \leq i \leq 3} X_i$ ,  $\hat{\theta}_2 = 4 \min_{1 \leq i \leq 3} X_i$ ,  $\hat{\theta}_3 = 2\bar{X}$  都是 $\theta$ 的无偏估计;
- 2) 上述三个估计量中哪个方差最小?

回忆: 当  $X \sim U(0, \theta)$ ,  $\theta$ 的矩法估计量为  $2\bar{X}$ , 而极大似然估计量为  $\max_{1 \leq i \leq n} \{X_i\}$ .

**分析:** 要判断估计量是否是无偏估计量, 需要计算**统计量的数学期望**.

令  $Y = \max_{1 \leq i \leq 3} X_i$ ,  $Z = \min_{1 \leq i \leq 3} X_i$





## 第七章 参数估计 — 估计量的优良性准则

证明: 1) 先求  $Y = \max_{1 \leq i \leq 3} X_i$  和  $Z = \min_{1 \leq i \leq 3} X_i$  的概率密度

$$\text{已知 } X \sim U(0, \theta), F_X(x) = \begin{cases} 0, & x \leq 0; \\ \frac{x}{\theta}, & 0 < x < \theta; \\ 1, & x \geq \theta. \end{cases}$$

$$F_Y(y) = P\{Y \leq y\} = P\{\max_{1 \leq i \leq 3} X_i \leq y\}$$

$$= P\{X_1 \leq y, X_2 \leq y, X_3 \leq y\}$$

$$= P\{X_1 \leq y\} \cdot P\{X_2 \leq y\} \cdot P\{X_3 \leq y\} = [F_X(y)]^3$$

$$F_Y(y) = \begin{cases} 0, & y \leq 0 \\ \left(\frac{y}{\theta}\right)^3, & 0 < y < \theta \\ 1, & y \geq \theta \end{cases} \quad \therefore f_Y(y) = \begin{cases} \frac{3}{\theta} \cdot \left(\frac{y}{\theta}\right)^2, & 0 < y < \theta \\ 0, & \text{else} \end{cases}$$





## 第七章 参数估计——估计量的优良性准则

先求  $Y = \max_{1 \leq i \leq 3} X_i$  和  $Z = \min_{1 \leq i \leq 3} X_i$  的概率密度函数:

$$\therefore f_Y(y) = \begin{cases} \frac{3}{\theta} \cdot \left(\frac{y}{\theta}\right)^2, & 0 < y < \theta \\ 0, & \text{else} \end{cases}$$

$$\therefore E(Y) = \frac{3}{\theta^3} \int_0^{\theta} y^3 dy = \frac{3}{4} \theta$$

同理可得,  $f_Z(z) = \begin{cases} \frac{3}{\theta} \cdot \left(1 - \frac{z}{\theta}\right)^2, & 0 \leq z \leq \theta \\ 0, & \text{else} \end{cases}$





## 第七章 参数估计——估计量的优良性准则

$$\therefore f_Y(y) = \begin{cases} \frac{3}{\theta} \cdot \left(\frac{y}{\theta}\right)^2, & 0 \leq y \leq \theta \\ 0, & \text{else} \end{cases} \quad f_Z(z) = \begin{cases} \frac{3}{\theta} \cdot \left(1 - \frac{z}{\theta}\right)^2, & 0 \leq z \leq \theta \\ 0, & \text{else} \end{cases}$$

$$\therefore E(Y) = \frac{3}{\theta^3} \int_0^\theta y^3 dy = \frac{3}{4} \theta \quad \hat{\theta}_1 = \frac{4}{3} \max_{1 \leq i \leq 3} X_i, \hat{\theta}_2 = 4 \min_{1 \leq i \leq 3} X_i, \hat{\theta}_3 = 2\bar{X}$$

$$\therefore E(Z) = \frac{3}{\theta^3} \int_0^\theta z \cdot (\theta - z)^2 dz = \frac{1}{4} \theta \quad Y = \max_{1 \leq i \leq 3} X_i, Z = \min_{1 \leq i \leq 3} X_i$$

$$\text{从而, } E\left(\frac{4}{3} \max_{1 \leq i \leq 3} X_i\right) = E\left(4 \min_{1 \leq i \leq 3} X_i\right) = \theta$$

$$E(\hat{\theta}_3) = E(2\bar{X}) = 2 \cdot \frac{\theta}{2} = \theta$$

$$\text{从而 } \hat{\theta}_1 = \frac{4}{3} \max_{1 \leq i \leq 3} X_i, \hat{\theta}_2 = 4 \min_{1 \leq i \leq 3} X_i, \hat{\theta}_3 = 2\bar{X} \text{ 都是 } \theta \text{ 的无偏估计.}$$





## 第七章 参数估计——估计量的优良性准则

$$\hat{\theta}_1 = \frac{4}{3} \max_{1 \leq i \leq 3} X_i, \hat{\theta}_2 = 4 \min_{1 \leq i \leq 3} X_i, \hat{\theta}_3 = 2\bar{X}$$

$$Y = \max_{1 \leq i \leq 3} X_i, Z = \min_{1 \leq i \leq 3} X_i$$

2) 上述三个估计量中哪个更有效?

$$\therefore D(Y) = E(Y^2) - E(Y)^2 = \frac{3}{80} \theta^2$$

$$D(Z) = E(Z^2) - E(Z)^2 = \frac{3}{80} \theta^2 \quad D(\hat{\theta}_3) = D(2\bar{X}) = 4 \cdot \frac{1}{3} \cdot \frac{\theta^2}{12}$$

$$\therefore D\left(\frac{4}{3}Y\right) = \frac{16}{9} D(Y) = \frac{16}{9} \cdot \frac{3}{80} \theta^2 \leq D(4Z) = 16D(Z) = 16 \cdot \frac{3}{80} \theta^2$$

$$D(\hat{\theta}_1) < D(\hat{\theta}_3) \quad \text{即 } \frac{4}{3} \max_{1 \leq i \leq 3} X_i \text{ 最有效.}$$

注: 这是最大似然估计优于矩估计的有名例子.

重要结论:  $\bar{X}$  和  $S^2$  分别是  $\mu$  和  $\sigma^2$  的最小方差无偏估计.





## 1. 无偏性

定义：设  $\hat{\theta}(X_1, X_2, \dots, X_n)$  是未知参数  $\theta$  的估计量，  
若  $E(\hat{\theta}) = \theta$ ，则称  $\hat{\theta}$  为  $\theta$  的无偏估计。 等价：  $E(\hat{\theta} - \theta) = 0$

2. 有效性：设  $\hat{\theta}_1(X_1, X_2, \dots, X_n)$  和  $\hat{\theta}_2(X_1, X_2, \dots, X_n)$   
是未知参数  $\theta$  的两个无偏估计量，如果  $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$   
则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  有效

估计量  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  与样本容量  $n$  也有关系，  
随着  $n$  增加，估计量的值越来越趋向于被估参数的真值，提出了

3. 相合性：设  $\hat{\theta}(X_1, X_2, \dots, X_n)$  是未知参数  $\theta$  的估计量，  
若对任意的  $\varepsilon > 0$ ，有  $\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1$  即  $\hat{\theta} \xrightarrow{P} \theta$   
则称  $\hat{\theta}$  为  $\theta$  的相合估计或一致估计。







## 相合估计量的证明

**例4** 设  $X \sim N(0, \sigma^2)$ , 证明:  $\frac{1}{n} \sum_{i=1}^n X_i^2$  是  $\sigma^2$  的相合估计量.

分析: 1) 证明相合性往往用到**切比雪夫不等式**, 其中涉及**期望与方差**;

$$P\{|X - E(X)| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2}$$

2) 这里计算方差较难, 可以先化为  $\chi^2$  分布, 再利用卡方分布的性质计算.

$$\text{令 } Y = \sum_{i=1}^n \left( \frac{X_i}{\sigma} \right)^2 \sim \chi^2(n) \quad \text{则 } \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\sigma^2}{n} Y$$





例4. 设  $X \sim N(0, \sigma^2)$ , 证明:  $\frac{1}{n} \sum_{i=1}^n X_i^2$  是  $\sigma^2$  的相合估计量。

证明:

$$E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^2) = \frac{1}{n} n E(X^2) = \sigma^2$$

$$\text{令 } Y = \sum_{i=1}^n \left(\frac{X_i}{\sigma}\right)^2 \sim \chi^2(n), \text{ 则 } \frac{1}{n} \sum_{i=1}^n X_i^2 = \frac{\sigma^2}{n} Y$$

$$\begin{aligned} \therefore D\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) &= D\left(\frac{\sigma^2}{n} Y\right) \\ &= \frac{\sigma^4}{n^2} \cdot D(Y) = \frac{\sigma^4}{n^2} \cdot 2n = \frac{2\sigma^4}{n} \end{aligned}$$





## 第七章 参数估计 — 估计量的优良性准则

例4. 设  $X \sim N(0, \sigma^2)$ , 证明:  $\frac{1}{n} \sum_{i=1}^n X_i^2$  是  $\sigma^2$  的相合估计量。

由切比雪夫不等式, 有

$$P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i^2 - E\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right)\right| \geq \varepsilon\right\} \leq \frac{D\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right)}{\varepsilon^2}$$

$$\begin{aligned} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i^2 - \sigma^2\right| \geq \varepsilon\right\} &\leq \frac{D\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right)}{\varepsilon^2} \\ &= \frac{2\sigma^4}{n\varepsilon^2} \xrightarrow[\varepsilon \text{ 固定}]{n \rightarrow \infty} 0 \end{aligned}$$

故  $\frac{1}{n} \sum_{i=1}^n X_i^2$  是  $\sigma^2$  的相合估计量。





## 小 结

重要结论:  $\bar{X}$  和  $S^2$  分别是  $\mu$  和  $\sigma^2$  的最小方差无偏估计;

$\bar{X}$  是  $\mu$  (总体期望) 的相合估计量; (例 7.2.4)

$S^2$  和  $M_2$  都是  $\sigma^2$  (总体方差) 的相合估计量。

样本的  $k$  阶原点矩  $A_k$  为总体矩  $\gamma_k$  的相合估计估计量

注: 由于相合性是在极限意义下定义的。

因此, 只有当样本容量充分大时, 才显示出优越性,

而在实际生活中往往难以增大样本容量,

而且证明估计量的相合性并非容易, 因此, 在实际生活

常常使用无偏性和有效性这两个标准(固定样本容量  $n$ )。

